

Обучение с подкреплением II

Нейросетевые рекомендательные
системы 2025/26, лекция 11

Кирилл Хрыльченко

Старший преподаватель,
ФКН ВШЭ

План занятия

Сегодня в программе:

1. Дойдём от next item prediction до обучения с подкреплением
2. Сформулируем марковский процесс принятия решений (MDP)
3. Посмотрим на алгоритм REINFORCE

На семинаре – разбор статей про применение RL в YouTube.

От рексистем до обучения с подкреплением


Часть 1

Next item prediction


Представим историю пользователя в виде последовательности событий $e_1, e_2, \dots, e_n$, и будем предсказывать будущее пользователя:

- Кодировем события в векторы
- Предсказываем следующее событие с помощью трансформера $p_{\theta}(e_t | e_1, \dots, e_{t-1})$
- e.g., SASRec

Получаем модель мира, в которой миром являются пользователи.



Рексистема как модель мира



- Какой потолок точности предсказания будущего?
- Что дальше делать с этой моделью?


Будущее нелинейно

- Объективная неопределенность
 - Квантовая механика
 - Свобода воли
- Субъективное незнание
 - Знаем только анонимизированную активность пользователя в сервисе


Дерево траекторий

Будущее пользователя – это дерево траекторий:

- Пользователь реализует одну из траекторий (и рексистема)
- Есть хорошие траектории (и плохие)
- Хотим повлиять так, чтобы реализовалась хорошая траектория



Влияние рексистемы



Myopic recommendations

- Обычная рекомендательная система выбирает рекомендации исходя из краткосрочной награды
 - Смотрит только на то, что произойдет сразу за рекомендацией
- А надо – оптимизировать долгосрочные метрики
 - Смотреть сразу на всю будущую траекторию

Exhaustive search

- Алгоритм:
 1. Нужно посчитать мат ожидание “хорошести” траектории после каждой возможной рекомендации
 2. Выбрать рекомендацию с максимальной “хорошестью”
- Это невозможно, если множества действий и событий большие

Recommender systems

1. Пользователь и рексистема вместе реализуют одну из траекторий
2. Есть хорошие траектории, есть плохие
3. Хотим с помощью рексистемы повлиять так, чтобы реализовалась хорошая траектория

Reinforcement learning

1. Пользователь – среда (мир), рексистема – агент
2. Можем определить для каждой траектории кумулятивную награду
3. Задаём для рексистему политику, действия - рекомендации

Reinforcement learning

Что можно сделать вместо полного перебора:

1. Обучить нейросеть-критика $Q(s, a)$, напрямую предсказывающую хорошесть действий
 - И действовать согласно $\operatorname{argmax}_a Q(s, a)$
2. Обучить политику (нейросеть-актера) $\pi(a | s)$, выдающую напрямую распределение по действиям
3. Оценивать мат ожидания с помощью модели мира, но без полного перебора
 - Сужать множество действий эвристиками
 - Сэмплировать траектории

Next item prediction

Пусть есть история покупок пользователя. Что нужно, чтобы точно предсказать следующую покупку?

- Уметь имитировать продакшн
- Понимать пользователей

Как только начнем использовать нашу модель предсказания покупок в проде, её точность упадёт. Почему?